

思考了 2m 2s

可以。对于“大肠杆菌全组学数据集”这个目标，我建议不要把它理解成“找几个数据库批量下载”，而是建设一个**可持续更新的 E. coli 多组学数据湖**：先把所有公开数据的 accession 和元数据收齐，再按研究价值逐层下载原始数据、处理数据和知识库数据。

从实际可行性看，最重要的设计是把数据集拆成两层：**K-12/MG1655 为核心的高一致性多组学集**，用于真正的跨组学整合；再建立 **E. coli species-wide 全菌株扩展集**，用于泛基因组、菌株差异、致病型/环境型比较。MG1655 的标准参考建议固定为 `GCF_000005845.2 / NC_000913.3 / U00096.3`。 [国家生物技术信... +1](#)

而且规模会比直觉大得多：NCBI 当前的 MG1655 条目本身就关联了约 1.9 万个 SRA experiments、数百个 GEO Series；整个 E. coli 物种相关 BioProject 更是上万级，因此“先抓元数据、再决定下载什么”非常重要。 [国家生物技术信... +1](#)


一、建议的数据集总体架构

建议最终形成下面这样的数据体系。

数据层	重点内容	核心来源	建议优先级
基因组 Genomics	完整基因组、WGS、SNP/InDel、质粒、泛基因组	NCBI Assembly/RefSeq/GenBank、ENA	★★★★★
转录组 Transcriptomics	RNA-seq、microarray、dRNA-seq、TSS、sRNA	GEO/SRA、BioStudies/ArrayExpress、ENA、iModulonDB	★★★★★
调控组 Regulomics	ChIP-seq、ChIP-exo、DAP-seq、gSELEX、TFBS、启动子、TU	RegulonDB、GEO/SRA	★★★★★
表观基因组 Epigenomics	PacBio/ONT methylome、DNA methylation motifs	SRA/ENA、REBASE	★★★★★
翻译组 Translatomics	Ribo-seq、ribosome profiling	GEO/SRA/ENA	★★★★★
蛋白组 Proteomics	shotgun、DIA、TMT、LFQ、absolute proteomics	ProteomeXchange、PRIDE、MassIVE、jPOST、iProX	★★★★★
PTM组	phospho、acetyl、methyl 等	ProteomeXchange/PRIDE/MassIVE	★★★★★

数据层	重点内容	核心来源	建议优先级
代谢组 Metabolomics	LC-MS、GC-MS、NMR、 targeted/untargeted	MetaboLights、 Metabolomics Workbench、 GNPS/MassIVE	★★★★★
脂质组 Lipidomics	lipid LC-MS/MS	MetaboLights、MW、GNPS	★★★★
通量组 Fluxomics	^{13}C tracing、MFA、代谢 流	Metabolomics repositories + supplement + EcoCyc/BiGG	★★★★★
相互作用组 Interactomics	PPI、AP-MS、Y2H、XL- MS、protein-DNA	IntAct、 ProteomeXchange、 BioGRID	★★★★★
功能基因组	Tn-seq、TraDIS、 essentiality、Keio phenotype	SRA/GEO、EcoCyc	★★★★★
表型组 Phenomics	Biolog、培养基、生长、碳 氮源、药敏	EcoCyc、BacDive	★★★★★
结构组	PDB/AlphaFold 结构	PDB、UniProt/AlphaFold DB	★★★
代谢网络/知识层	reaction/pathway/GPR/TF- network	EcoCyc、RegulonDB、 BiGG、ECMDB	★★★★★
跨库发现层	各类 accession 统一发现	OmicsDI	★★★★★

这里特别推荐把 **OmicsDI** 当“总目录搜索器”而不是下载源。OmicsDI 可以统一按 taxonomy 和 omics type 搜索 PRIDE、MassIVE、PeptideAtlas、MetaboLights、Metabolomics Workbench、GNPS、ArrayExpress、Expression Atlas、GEO、ENA 等数据库，非常适合作为查漏补缺层。



二、序列组学不要重复下载 NCBI、ENA、DDBJ

这是整个方案里一个非常重要的节省空间点。

NCBI GenBank/SRA、EMBL-EBI ENA 和 DDBJ 属于 INSDC，三方会交换序列数据，所以原则上同一份原始测序数据只选一个主下载源。没有必要把 SRR、ERR、DRR 在三个地方各下载一次。

我的建议是：

NCBI 用于 Assembly、BioProject、BioSample、GEO、RefSeq 体系；ENA 用作大批量 FASTQ 下载备用/甚至主通道。

ENA 的优势是 Portal API 可以直接返回 `fastq_ftp`、MD5 和字节数，特别适合先计算数据规模。ENA 还明确支持大规模结果 `limit=0`，并可以通过 FTP、Aspera、Globus 或 enaBrowserTools 下载。 [📖 ENA文档 +1](#)

例如，第一步甚至可以只取得所有 E. coli 测序数据的 manifest，而一条 FASTQ 都不下载：

Bash

```
curl -G 'https://www.ebi.ac.uk/ena/portal/api/search' \
  --data-urlencode 'result=read_run' \
  --data-urlencode 'query=tax_tree(562)' \
  --data-urlencode 'fields=run_accession,study_accession,sample_accession,tax_id,scientific_name' \
  --data-urlencode 'format=tsv' \
  --data-urlencode 'limit=0' \
  > ecoli_ena_all_runs.tsv
```

ENA 官方支持用 taxonomy subtree 进行这种检索，因此 `tax_tree(562)` 比简单关键词 `"Escherichia coli"` 更可靠。 [📖 ENA文档](#)

这样得到的表实际上就是你后面所有 sequencing omics 的第一版总目录。

三、具体实施流程

我建议按下面 8 个阶段实施，而不是直接下载 PB/TB 级的数据。

1. 固定参考体系。Species-wide 使用 `NCBI TaxID 562`；多组学核心数据使用 MG1655 `TaxID 511145`，参考基因组固定为 `GCF_000005845.2 / NC_000913.3`。另外单独保留 BW25113、W3110、BL21/B 系、REL606、O157:H7、CFT073 等常用菌株层，绝不能把不同 strain 的 gene expression 直接当成同一个基因组坐标系。
2. 只抓 metadata，暂不抓 raw data。分别生成 `ncbi_assembly.tsv`、`ena_runs.tsv`、`geo_series.tsv`、`proteomexchange.tsv`、`metabolights.tsv`、`mw.tsv`、`omicsdi.tsv` 等。这个阶段先回答三个问题：到底有多少实验、各组学多少、原始数据需要多少 TB。
3. 构建 accession 图谱。把 `BioProject → Study → BioSample → Experiment → Run → file` 关联起来，同时关联 GEO GSE/GSM、PRIDE PXD、MetaboLights MTBLS、MW ST、DOI/PMID。不要把 accession 当成简单文件名，而要把它做成关系型目录。

4. **数据分类。** 将项目分为 genomics、RNA-seq、ChIP、Ribo-seq、methyloome、Tn-seq、proteomics、metabolomics、fluxomics 等。由于 `library_strategy` 经常填写不规范，应该同时结合 title、abstract、library_selection、protocol 和 publication 做二次分类。
5. **先下载 Core Multi-omics。** 首批只下载 MG1655/BW25113/W3110 等模式株的 RNA、protein、metabolite、Ribo、ChIP、Tn-seq 等数据。这样最快能够构建真正可工作的多组学矩阵，然后再扩展到所有菌株。
6. **再下载 Species-wide 数据。** Genomics 优先下载 assembly，而不是把所有 WGS FASTQ 全部下载；只有需要重新 assembly、variant calling 或 QC 时才拉 raw reads。RNA/proteome/metabolome 则根据 metadata 和 QC 打分选择。
7. **统一处理和标准化。** DNA/RNA 等全部统一映射到确定的 reference version；species-wide 用 ortholog/pangenome gene family 作为整合单位；蛋白以 UniProt/gene/locus tag 映射；代谢物统一映射到 ChEBI/InChIKey/KEGG compound 等稳定 ID。
8. **建立可更新 manifest。** 每隔一段时间只重新查询 accession 和发布日期，然后下载新增数据。数据湖应做到“append-only”，原始文件永不覆盖，processed 数据按 pipeline version 保存。

四、基因组层：建议分成“参考基因组库”和“species-wide assembly 库”

MG1655 核心参考可以直接使用：

Bash

```
datasets download genome accession GCF_000005845.2 \
--include genome,rna,cds,protein,gff3,gbff,seq-report \
--filename MG1655.zip
```

NCBI Datasets 可以按 taxon、assembly accession 或 BioProject 下载 genome、RNA、CDS、protein、GFF3、GBFF 等。 [国家生物技术信... +1](#)

species-wide 千万不要直接一次性下载普通 ZIP。对于超过 1,000 个 genome 或 15 GB 的包，NCBI 官方推荐使用 dehydrated package：

Bash

```
datasets download genome taxon 562 \
--dehydrated \
--include genome,gff3,gbff,protein,rna,cds \
--filename ecoli_all_genomes.zip

unzip ecoli_all_genomes.zip -d ecoli_all_genomes
```

```
datasets rehydrate \  
  --directory ecoli_all_genomes \  
  --gzip \  
  --max-workers 20
```

这是 NCBI 官方针对大型 genome collection 推荐的工作方式。

 国家生物技术信... +1

第一版我甚至建议只选：

```
complete + chromosome + annotated RefSeq
```

建立高质量泛基因组，之后再加入 scaffold/contig。

五、转录组：GEO + SRA/ENA + BioStudies + iModulonDB

这里要理解 GEO/SRA 的角色不同。

GEO 是实验设计、**sample metadata** 和 **processed matrix** 的重要来源，**SRA/ENA** 是 **raw reads** 来源。因此同一个 RNA-seq 项目通常应该同时保留 GEO metadata/processed data 和 SRA FASTQ，而不能只选一个。

欧洲侧原 ArrayExpress 数据现在主要放入 BioStudies；对于 sequencing studies，raw FASTQ 通常链接到 ENA，而实验 metadata 和 processed data 保留在 BioStudies。

 EMBL-EBI +1

此外，非常推荐引入 **iModulonDB/PRECISE** 作为预处理后的高质量表达层。E. coli PRECISE 数据集包含 MG1655/BW25113 多条件 RNA-seq compendium，非常适合做 transcriptional modules、ICA 和跨条件整合。

 iModulonDB

因此 transcriptome 最终应保留三份：

```
raw FASTQ  
  ↓  
统一 pipeline 得到自己的 expression matrix  
  ↓  
原作者 processed matrix  
  
同时保留：  
GEO/iModulonDB 已整理数据用于验证
```

这会比单纯收集 TPM 文件可靠得多。

六、调控组：RegulonDB 是必须下载的数据源

对 E. coli 做整合组学，RegulonDB 几乎是不可缺的。

它不只是 TF→gene 数据库，还收集了大量高通量 transcriptional regulation 数据，包括 RNA-seq、ChIP-seq、ChIP-exo、gSELEX、DAP-seq、TSS、termination sites、transcription units 等。RegulonDB 已将大量 HT datasets 进行统一处理。

 PubMed Centra... +1

最终你可以构建：

```
TF
↓
binding site
↓
promoter
↓
transcription unit / operon
↓
gene
↓
RNA abundance
↓
protein abundance
↓
metabolite / reaction / flux
```

这其实是 E. coli 比很多其他物种更适合做 multi-omics integration 的原因之一。

七、蛋白质组：不要只查 PRIDE，要从 ProteomeXchange 总入口开始

蛋白组建议使用：

ProteomeXchange / ProteomeCentral → PRIDE + MassIVE + jPOST + iProX + PeptideAtlas/PASSEL

ProteomeXchange 的 universal archival repositories 包括 PRIDE、MassIVE、jPOST、iProX，另外还有针对性资源。  蛋白质组交换 +1

PRIDE 提供 REST API，可以按 project 搜索并获取每个项目的 file list。  EMBL-...

E. coli 的数据类型相当丰富，包括 absolute protein abundance、DIA、TMT、LFQ、phosphoproteomics、acetylation 等。例如经典的 condition-dependent E. coli proteome 数据集 PXD000498 就覆盖 22 种条件、超过 2,300 个蛋白。  ProteomeCentral

蛋白组最好同时保存：

```
vendor RAW
mzML
mzIdentML / mzTab / search-engine output
protein abundance matrix
peptide abundance matrix
PTM site table
experimental metadata
```

第一轮如果硬盘有限，可以只下载 processed results + metadata；真正进入某个专题研究时，再下载 RAW 做统一重分析。

八、代谢组：至少覆盖三大体系

这里建议同时检索：

MetaboLights + Metabolomics Workbench + GNPS/MassIVE

MetaboLights 的所有公开 study 都可以下载，并使用标准化 ISA-Tab 描述 experiment/sample/assay。它支持 FTP、API、Aspera/Globus 等方式。

EMBL-EBI +1

Metabolomics Workbench 也提供 REST API，可程序化获取 study metadata、results 和 metabolites；其 repository 支持 raw 和 processed data。

代谢组学工作台 +1

现有 MW 中已经存在不少 E. coli 的 metabolomics 项目，包括 long-term evolution experiment、不同培养基/时间点、biofilm、virulence-associated metabolites 等。

代谢组学工作台

另外强烈建议下载 **ECMDB**，但要注意它和 MetaboLights 的性质不同：

ECMDB 是 E. coli K-12/MG1655 专门的 curated metabolome knowledgebase，可以直接下载 metabolites JSON、SDF、蛋白/基因 FASTA；非常适合建立 metabolite master dictionary。

ECMDB +1

也就是说：

```
MetaboLights / MW / GNPS
    ↓
实验数据

ECMDB / EcoCyc
    ↓
代谢物身份 + reaction + pathway knowledge
```

两者都需要。

九、表观组和 methylome

E. coli 这里建议将 PacBio/ONT sequencing data 和 REBASE 结合。

PacBio SMRT sequencing 很多时候能够直接产生 methylation motif 信息。REBASE 专门收集 restriction-modification systems、DNA methyltransferase、recognition motif，以及来自 PacBio 的 methylome 信息，并提供可下载数据。 [PubMed Central](#)

因此这一层可以做成：

```
PacBio / ONT raw
↓
modified base calls
↓
methylated motif
↓
REBASE MTase
↓
gene expression / TF binding changes
```

这个层面对研究 stress、phage defense、restriction-modification 和 strain-specific regulation 很有价值。

十、相互作用组与网络层

如果最终目的是 integrative omics，而不是简单相关性分析，建议把 experimentally curated PPI 加进去。

首选 **IntAct**。它提供文献人工整理和直接提交的 molecular interaction 数据，可以通过 FTP、REST、PSICQUIC 下载，并支持 PSI-MI 标准。 [EMBL-EBI +1](#)

E. coli 已经存在经典 large-scale protein-protein interaction datasets。 [EMBL-...](#)

STRING 可以作为预测/functional association 层，但不要和 experimental PPI 混成一种 evidence。

最终每条 edge 最好带：

```
geneA
geneB
interaction_type
experimental_method
```

source
PMID
confidence
experimental/predicted

十一、EcoCyc 应该作为整个系统的“知识骨架”

如果只能选一个 E. coli 专门数据库，我会选 **EcoCyc**。

EcoCyc 的核心是 MG1655，覆盖 genome、genes、proteins、metabolites、reactions、pathways、regulation、essentiality、growth conditions 等，并且维护 genome-scale metabolic model。 [PubMed +1](#)

因此建议最终把所有组学都投影到 EcoCyc 的生物学框架：

```
DNA variant
  ↓
gene / operon
  ↓
transcription
  ↓
protein
  ↓
enzyme
  ↓
reaction
  ↓
metabolite
  ↓
pathway
  ↓
phenotype
```


这会比简单做 RNA–protein–metabolite 的 Pearson correlation 强很多。

十二、Fluxomics 和 genome-scale model

建议引入 **BiGG iML1515**。

iML1515 是 E. coli K-12 MG1655 的 genome-scale metabolic model，以 [NC_000913.3](#) 为 reference，目前模型包含 1,516 genes、2,712 reactions、1,877 metabolites，并可下载 SBML、JSON 和 MAT。 [BiGG Models](#)

它特别适合之后做：



因此虽然 BiGG 不是“原始组学数据库”，但在 integrative omics 中价值非常高。

十三、最重要的元数据表怎么设计

我建议你的核心表不是“表达矩阵”，而是一个 `sample_manifest.parquet`。

至少应该包含：

类别	建议字段
Identity	project_id、study_id、sample_id、run_id
Organism	taxid、species、strain、substrain
Genome	assembly、reference_accession
Experiment	omics_type、assay_type、platform、instrument
Condition	medium、carbon_source、nitrogen_source、oxygen
Growth	temperature、pH、OD、growth_phase
Perturbation	gene knockout、overexpression、drug、stress
Time	timepoint、duration
Replicate	biological_rep、technical_rep
Sequencing	layout、read_length、library_strategy
File	URL、MD5、bytes、format
Literature	PMID、DOI

类别	建议字段
Provenance	repository、accession、download_date
QC	qc_status、exclusion_reason

这里尤其要认真整理：

strain + medium + growth phase + treatment + time point + temperature + oxygen

因为对于 E. coli 来说，RNA、protein 和 metabolite 的变化很多时候主要就是这些条件导致的。

十四、多组学整合时不要把“多组学”只定义成一种

建议在你的数据库里增加：

```
integration_level
```

并分成三类：

Level	定义	价值
A	同一个 biological sample 做 RNA/protein/metabolite 等	最高
B	同项目、同菌株、同 condition，但不同样本	很高
C	不同项目，但菌株/培养条件可匹配	可用于 meta-analysis

这一步非常关键。

实际上公开数据中真正的 **matched multi-omics sample** 远少于“分别存在 RNA-seq 和 proteomics”的数据。

如果不把 A/B/C 分开，后期很容易产生伪相关。

十五、推荐的最终存储结构

我会这样设计：

```
EcoliOmics/
|
├─ manifests/
|   ├── studies.parquet
|   ├── samples.parquet
|   ├── assays.parquet
|   ├── files.parquet
|   └─ accession_crossref.parquet
|
├─ reference/
|   ├── MG1655/
|   ├── EcoCyc/
|   ├── RegulonDB/
|   ├── UniProt/
|   ├── ECMDB/
|   └─ BiGG/
|
├─ genomics/
|   ├── assemblies/
|   ├── variants/
|   └─ pangenome/
|
├─ transcriptomics/
|   ├── raw/
|   ├── processed/
|   └─ expression_matrix/
|
├─ regulomics/
|
├─ riboseq/
|
├─ methylomics/
|
├─ proteomics/
|   ├── raw/
|   ├── mzML/
|   └─ abundance/
|
├─ metabolomics/
|   ├── raw/
|   ├── mzML/
|   └─ abundance/
|
├─ fluxomics/
|
├─ interactomics/
|
├─ phenomics/
|
└─ integrated/
    ├── gene_master.parquet
```

```
└─ metabolite_master.parquet
└─ ortholog_master.parquet
└─ sample_matched_multiomics.parquet
└─ condition_matched_multiomics.parquet
```

大型 expression/abundance matrix 推荐 Parquet/HDF5/Zarr，不建议全部 CSV。

十六、我建议你的实际优先级

如果你的最终目标是多组学/整合组学研究，而不是纯粹建设数据库，第一阶段不要立刻把 species-wide 的所有 WGS 下载下来。

最有研究产出的顺序应该是：

MG1655/BW25113 核心集 → RNA + proteome + metabolome + ChIP/regulation + Ribo + phenotype → EcoCyc/RegulonDB 网络 → matched-condition integration → 再扩展 species-wide genomics/pangenome。

这样最先能够形成一个真正可分析的矩阵：

```
          Sample 1   Sample 2   ... Sample N
RNA
gene1
gene2

Protein
gene1
gene2

Metabolite
met1
met2

Flux
rxn1
rxn2

Phenotype
growth
MIC
```

以及一个知识图谱：

```
TF → Gene → RNA → Protein → Reaction → Metabolite
      |               |
      └─ Essentiality ┘ Flux
```

这套结构既能做传统 multi-omics，也能做 MOFA、DIABLO、NMF/ICA、CCA、network integration、GNN、knowledge graph、metabolic modeling、causal inference 等。

整体上，我会把这项工作定义成一个“**EcoliOmics Data Lake + Ecoli Knowledge Graph**”项目，而不是一次性下载任务。

如果你准备真正开始实施，我下一步可以直接给你整理一套可执行版本：包括数据库清单、每个数据库的 API/FTP 下载方式、TaxID/查询式、目录结构、metadata 字段定义，以及一套 Python + Bash/Snakemake 自动下载脚本，先做到“运行一个 pipeline 自动生成大肠杆菌全组学 accession 清单并统计需要多少 TB”，再按组学逐步下载。